

J1 — Introduction à R et à la pensée spatiale

Atelier régional IFORD × GDSG · Yaoundé · 27 juillet 2026

Ramesesse Dzita · Geospatial Data Science Group

2026-07-27

Partie 0 — Cadre de la journée

Bienvenue à l'IFORD

Atelier régional R-Spatial

10 jours · 27 juillet – 7 août 2026

Première collaboration officielle entre :

- **IFORD** — Institut de Formation et de Recherche Démographiques
- **GDSG** — Geospatial Data Science Group de l'IFORD

Public attendu

Statisticiens d'Instituts Nationaux de Statistique, démographes IFORD, techniciens de ministères sectoriels, chargé·es d'études d'ONG et d'organisations internationales — Afrique francophone et anglophone.

Niveau visé : opérationnel sur un microfichier d'enquête + premières cartes thématiques propres en R.

Tour de table — 2 minutes par personne

1. Nom, institution, pays, fonction.
2. Domaine d'analyse principal (santé, éducation, environnement, recensement, suivi de programmes...).
3. Expérience préalable : R, SIG (QGIS, ArcGIS, SAS Mapping...), Python.
4. **Une attente concrète** pour les 10 jours.

Le rythme de la journée est calibré en temps réel sur ce tour de table. Sois précis sur ce que tu sais déjà faire et sur ce qui te bloque aujourd'hui.

Le programme à 10 000 mètres

Phase	Jours	Thème dominant
Fondations	J1 – J3	R, sf, CRS, cartographie thématique
Analyse appliquée	J4 – J7	Raster (terra), jointures spatiales, statistiques spatiales, télédétection
Population & restitution	J8 – J10	Estimation top-down, bottom-up, mini-projet de synthèse

L'arc narratif : on part d'un `data.frame` plat et on aboutit, en 10 jours, à des cartes de population pour micro-zones du Cameroun, méthodologiquement défendables face aux exigences du RGPH 4.

Partie 1 — Plan détaillé de J1

Articulation de la journée (8 heures)

Bloc	Durée	Format
Cadre + théorie 1 : R dans l'écosystème statistique	0h45	Slides
Théorie 2 : grammaire <code>tidy</code> et verbes <code>dplyr</code>	0h45	Slides
Démo 1 + exercices Q1–Q3 : R comme calculatrice, <code>dplyr</code> appliqué	1h30	<code>demo.qmd</code> + console + <code>exercice.qmd</code>
Théorie 3 : Simple Features, anatomie d'un objet <code>sf</code>	0h45	Slides
Démo 2 : charger les ADM Cameroun, première carte	1h00	<code>demo.qmd</code>
Théorie 4 : la pensée projective (CRS,	1h30	Slides

Bloc	Durée	Format
cartographie critique)		
Démo 3 + exercices Q4–Q5 : reprojection, Web Mercator, choroplèthe densité	1h00	<code>demo.qmd</code> + <code>exercice.qmd</code>
Cadrage RGPH 4 + synthèse + Q&A	0h45	Slides

Trois fichiers, trois rôles

`slides.qmd` (ici)

Plan, théorie, références, schémas conceptuels, cadrage méthodologique.

Zéro code à taper.

`demo.qmd` + `demo.R`

Code R commenté, exécuté en salle. Pour chaque commande : une explication courte avant.

Code écrit ensemble.

`exercice.qmd` +

`corrige.qmd`

Q1–Q5 micro-exercices en séance (5–10 min chacun) + Q6 devoir individuel du soir.

Code que tu écris seul·e.

Objectifs pédagogiques de J1

À la fin de la journée, chaque participant doit pouvoir :

1. **Naviguer** dans RStudio et créer un projet reproductible avec [here](#).
2. **Manipuler** un microfichier d'enquête démographique camerounaise — vecteurs, indexation, filtres, agrégats — en utilisant les cinq verbes `dplyr`.
3. **Distinguer** conceptuellement un `data.frame` d'un objet spatial `sf`.
4. **Charger** les limites administratives du Cameroun (GADM v4.1) et produire une première carte propre.
5. **Énoncer** ce qu'est un système de coordonnées de référence (CRS) et **expliquer** pourquoi le confondre cause des erreurs de plusieurs kilomètres voire dizaines de pourcents sur les superficies.

Partie 2 — R dans l'écosystème

Quatre options pour analyser des données démographiques

Outil	Force	Faiblesse	Coût
Excel	Saisie + visualisation rapide	Non reproductible, traçabilité nulle	Licence MS Office
Stata	Excellence statistique, syntaxe stable	Écosystème géospatial pauvre	~\$1700/an
SPSS	Interface graphique conviviale	Coûteux, peu de communauté ouverte	~\$1200/an
R	Open source, écosystème géospatial mature	Courbe d'apprentissage initiale	Gratuit

L'objectif de la formation n'est **pas** de remplacer Stata, c'est d'**augmenter** la boîte à outils d'une dimension spatiale qui n'existe sérieusement que

Pourquoi R domine la statistique spatiale aujourd'hui

Quatre facteurs convergent depuis 2018 ([Pebesma 2018](#)) :

1. **Standard ouvert** : le format OGC Simple Features est une norme ISO (19125), implémentée à l'identique dans QGIS, PostGIS, GDAL et `sf` — interopérabilité native.
2. **Adoption institutionnelle** : WorldPop, le DHS Program, l'INED, l'INSEE, l'INSPQ publient leur code de référence en R.
3. **Reproductibilité scientifique** : Quarto / R Markdown sont devenus le standard de fait dans les revues à comité de lecture (par ex. *Nature* depuis 2022).
4. **Souveraineté numérique** : pas de dépendance à un éditeur privé, déployable dans toute institution africaine sans contrainte budgétaire.

La pile R-spatiale en 2026

Une trajectoire de 25 ans qui se condense

1999 — l'OGC publie la norme Simple Features.

2005 — package `sp` (Bivand, Pebesma) : premier R sérieux pour le spatial.

2015 — Stevens, Tatem et al. publient la méthodologie WorldPop top-down ([Stevens et al. 2015](#)).

2018 — package `sf` (Pebesma) : adoption massive, `sp` devient hérité.

2020 — package `terra` (Hijmans) ([Hijmans 2024](#)) : succession de `raster`.

2023 — Darin & Leasure proposent la méthodologie WorldPop bottom-up ([Darin and Leasure 2023](#)).

2024 — `quarto-live` : R s'exécute directement dans le navigateur (WebR).

C'est cette trajectoire qu'on traverse en 10 jours.

Partie 3 — Grammaire des données rectangulaires

Une convention vieille de 50 ans : le `data.frame`

Le tableau « lignes × colonnes » est la structure dominante de toute analyse démographique depuis les premiers recensements informatisés (années 1960). En R :

- **Lignes** = observations (un ménage, un individu, une zone)
- **Colonnes** = variables (âge, sexe, région, indicateur)
- **Cellules** = valeurs typées (numeric, character, logical, factor)

Le `data.frame` impose deux contraintes :

1. Toutes les colonnes ont la **même longueur**.
2. Chaque colonne est d'un **type unique** (pas de mélange "abc" et 42 dans la même colonne).

Le `data.frame`, le `tibble` et la philosophie tidy

Le `tibble` (tidyverse, 2017) est un `data.frame` qui durcit quelques règles :

- pas de conversion silencieuse des chaînes en facteurs ;
- affichage console borné (10 lignes par défaut) ;
- refus de l'indexation par nom partiel ambigu.

C'est la même structure logique avec une **discipline défensive** plus stricte. En production, le `tibble` évite plusieurs classes de bugs subtils que le `data.frame` classique laisse passer.

Tidy data : trois règles d'or (Wickham 2014)

Hadley Wickham, en 2014, a formalisé ce qu'on appelle aujourd'hui le « tidy data » :

1. **Chaque variable forme une colonne.**
2. **Chaque observation forme une ligne.**
3. **Chaque type d'unité statistique a sa propre table.**

Ces trois règles paraissent triviales mais leur violation est massive dans les microfichiers réels (DHS, MICS, ECAM). Exemple typique : un tableau avec une colonne par année — c'est **wide**, ce n'est pas tidy. On transforme avec `tidyr::pivot_longer()`.

80 % du temps d'un démographe sur un microfichier neuf est consacré à le rendre tidy. Une fois tidy, les analyses prennent quelques minutes.

Les cinq verbes de dplyr

Verbe	Action	Question typique
<code>filter()</code>	Garder certaines lignes	Quels ménages urbains du Centre ?
<code>select()</code>	Garder certaines colonnes	Que la région et l'effectif
<code>mutate()</code>	Créer ou modifier une colonne	Calculer la densité = pop / surface
<code>group_by()</code> + <code>summarise()</code>	Agréger par modalité	Taux d'électrification par région
<code>arrange()</code>	Trier les lignes	Par densité décroissante

Ces cinq verbes couvrent ~80 % de ce que fait un démographe sur un microfichier propre. Les 20 % restants : jointures (`*_join`), pivots (`pivot_*`), opérations fenêtre (`mutate(... = lag(.x))`).

Le pipe natif |> se lit « puis »

Code en chaîne (lecture intérieur → extérieur) :

```
arrange(select(filter(tbl_cmr, pop_2019 > 3e6),  
               region, capitale, pop_2019),  
        desc(pop_2019))
```

Pipe natif (lecture haut → bas, comme une phrase) :

```
tbl_cmr |>  
  filter(pop_2019 > 3e6) |>  
  arrange(desc(pop_2019)) |>  
  select(region, capitale, pop_2019)
```

Traduction orale :

« Prendre `tbl_cmr`, **puis** filtrer les régions de plus de 3 M, **puis** trier par population décroissante, **puis** ne garder que ces trois colonnes. »

Le pipe rend le code **lisible à voix haute** — c'est ce qui permet à un démographe sans formation en programmation de comprendre, modifier et auditer un script.

dplyr VS data.table : quand sortir de la grammaire tidy ?

dplyr est conçu pour la **lisibilité**, pas la performance maximale. Sur un microfichier d'enquête (< 1 M lignes), la différence est imperceptible.

Au-delà : un fichier individu DHS panafricain (~50 M lignes), un microfichier de recensement RGPH (~25 M individus pour le Cameroun)
— data.table peut être 10–100× plus rapide.

Règle pragmatique : démarrer en dplyr (lisibilité, audit, transmission), basculer en data.table seulement si le temps de calcul devient un blocage.

Partie 4 — Du tableau à la géométrie

L'intuition fondatrice

Un `data.frame` classique :

region	population	densité
Centre	4 400 000	105
Littoral	3 400 000	168
...	...	...

Un objet **spatial** = ce même `data.frame` + **une colonne supplémentaire** appelée `geometry`, qui contient un point, une ligne ou un polygone pour chaque ligne.

region	population	densité	geometry
Centre	4 400 000	105	MULTIPOLYGON(...)
Littoral	3 400 000	168	MULTIPOLYGON(...)
...	...	...	...

Simple Features : un standard mondial

Le format **Simple Features** est défini par l'Open Geospatial Consortium (OGC) depuis 1999, normalisé ISO 19125 en 2004.

Sept types géométriques de base :

- **POINT** — un lieu
- **LINESTRING** — une route, un cours d'eau
- **POLYGON** — une parcelle, une région
- **MULTIPOINT** — un nuage de points
- **MULTILINESTRING** — un réseau
- **MULTIPOLYGON** — un archipel, une région à plusieurs morceaux
- **GEOMETRYCOLLECTION** — mélange

Ces sept types sont implémentés **à l'identique** dans **sf** (R), **geopandas** (Python), **QGIS**, **PostGIS**, **ArcGIS**. Un Shapefile lu par QGIS et lu par R produit exactement la même structure logique.

Les trois bibliothèques C/C++ derrière `sf`

`sf` n'est qu'un *wrapper* R autour de trois bibliothèques système qui font le vrai travail :

Bibliothèque	Rôle	Version utile
GDAL	Lecture / écriture de tous les formats SIG (Shapefile, GeoJSON, GeoPackage, GeoTIFF, NetCDF...)	≥ 3.8
GEOS	Opérations géométriques (intersection, union, distance, contains, touches...)	≥ 3.12
PROJ	Transformations de projection (<code>st_transform</code>)	≥ 9.3

L'héritage multiple de `sf` : `data.frame` ET objet spatial

```
class(adm1)
> "sf" "data.frame"
```

L'objet `adm1` est **simultanément** :

- un `data.frame` — donc `dplyr` (`filter`, `mutate`, `summarise`) fonctionne directement ;
- un `sf` — donc les opérations spatiales (`st_area`, `st_distance`, `st_transform`, `st_intersection`) fonctionnent aussi.

C'est ce double héritage qui rend `sf` aussi puissant pour la statistique spatiale : **le même objet** porte les attributs et la géométrie, et les deux familles d'opérations cohabitent sans heurts.

Pourquoi `sf` a remplacé `sp` (et pourquoi c'est définitif)

`sp` (Bivand & Pebesma, 2005) — premier R sérieux pour le vectoriel.
Encore vivant mais en mode maintenance.

`sf` (Pebesma, 2018) ([Pebesma 2018](#)) — adopté par toute la communauté en 5 ans :

Critère	<code>sp</code>	<code>sf</code>
Conformité OGC Simple Features	partielle	totale
Intégration tidyverse	non	native
Performance sur gros fichiers	OK	5–10× plus rapide
Maintenance active en 2026	maintenance	développement actif
Documentation	datée	excellente

En 2026 : utiliser `sf`, pas `sp`. Tout tutoriel basé sur `sp` est à éviter sauf pour comprendre du code hérité.

Partie 5 — La pensée projective

Pause de 5 à 10 min juste avant cette partie. C'est la séance la plus dense de J1.

La Terre : modèle, ellipsoïde, géoïde

De la sphère au plan : la projection

Une **projection** est une fonction mathématique qui transforme des coordonnées sphériques (longitude, latitude — en degrés) en coordonnées planes (x, y — en mètres).

Théorème de Gauss (1828) : il n'existe **aucune** projection qui préserve simultanément les angles, les aires et les distances. Chaque projection sacrifie au moins une de ces trois propriétés.

Trois familles selon ce qu'on choisit de préserver :

Famille	Préserve	Sacrifice	Usage typique
Conforme	Angles localement	Aires	Navigation, cartographie web
Équivalente (equal-area)	Aires	Angles	Statistique, choroplèthes
Équidistante	Distances depuis un point	Aires + angles	Cartes de distance

EPSG : un catalogue mondial depuis 1985

L'**European Petroleum Survey Group** (EPSG) maintient depuis 1985 un catalogue de tous les systèmes de coordonnées utilisés dans le monde. Aujourd'hui géré par l'IOGP (International Association of Oil & Gas Producers).

Chaque CRS a un identifiant numérique. Quelques codes à retenir :

EPSG	Nom	Type	Usage
4326	WGS 84	Géographique (degrés)	Standard d'échange — GPS, GeoJSON, KML
32632	UTM zone 32 N	Projeté (mètres)	Ouest du Cameroun
32633	UTM zone 33 N	Projeté (mètres)	Est du Cameroun
3119	Lambert Cameroun	Projeté (mètres)	Cartographie nationale uniforme

EPSG	Nom	Type	Usage
3857	Web Mercator	Projeté (déformé)	Fonds OSM, Google Maps
3035	ETRS89 / LAEA	Projeté équivalent	Statistique européenne, Eurostat

Web Mercator : la projection qui ment

Web Mercator (EPSG:3857) est le standard de fait des fonds de carte web (OpenStreetMap, Google Maps, Mapbox). C'est une projection **conforme** — elle préserve localement les angles.

Conséquence : à mesure qu'on s'éloigne de l'équateur, **les aires sont sur-estimées d'un facteur exponentiel** :

Latitude	Facteur de distorsion d'aire
0° (équateur)	× 1.00
11° N (Maroua)	× 1.04
30° N (Le Caire)	× 1.33
60° N (Stockholm)	× 4.00
80° N (Spitzberg)	× 33

 Règle absolue

Web Mercator est interdit pour toute statistique spatiale. Réservé strictement aux fonds de carte
IFORD × GDSG 2026 — J1 · Intro R + pensée spatiale

La carte comme acte politique

La projection de Mercator (1569) a longtemps été la projection scolaire dominante. Conséquence visuelle : le Groenland paraît aussi grand que l'Afrique. Or :

- Afrique = 30 370 000 km²
- Groenland = 2 166 000 km²

Le Groenland est 14 fois plus petit que l'Afrique — mais Mercator les présente comme équivalents.

La projection de Gall-Peters (1974) a été promue précisément en réaction à ce biais, popularisée par les écoles de Boston en 2017. C'est une projection équivalente — les aires sont fidèles, au prix d'angles déformés.

Choisir une projection, c'est choisir ce qu'on **veut faire voir**. Une carte n'est jamais neutre.

Pour le Cameroun : quel CRS pour quelle question ?

Question	CRS recommandé	Pourquoi
Stocker des données GPS terrain	4326 (WGS 84)	Standard de tous les GPS et formats d'échange
Calculer une distance entre deux villes	UTM 32 N ou 33 N (selon longitude)	Coordonnées en mètres
Calculer la superficie d'une région	UTM ou Lambert Cameroun (3119)	Projection équivalente, faible déformation
Carte choroplèthe nationale	Lambert Cameroun (3119)	Faible déformation sur l'ensemble du pays
Fond de carte web interactif	Données en UTM → laisser leaflet reprojeter en 3857 à l'affichage	Calculs corrects, affichage compatible OSM

L'erreur silencieuse : `st_set_crs()` $\neq$ `st_transform()`

`st_set_crs(x, 4326)`

= « ÉTIQUETTE cet objet comme étant en WGS 84 »

— ne touche **pas** aux coordonnées.

Utile uniquement si le CRS est manquant (par exemple un Shapefile sans `.prj`).

`st_transform(x, 4326)`

= « REPROJETTE cet objet vers WGS 84 »

— **recalcule** chaque coordonnée.

C'est l'opération qu'on veut 99 % du temps.

Confondre les deux est l'erreur silencieuse n°1 en SIG. Le résultat compile, ne lève aucun warning, et place tous les points à des kilomètres de leur vraie position. Tests systématiques de cohérence : `st_bbox()` après l'opération, et comparer à l'emprise attendue du Cameroun (longitude 8.5°–16.2°, latitude 1.7°–13°).

Partie 6 — Cartographier, c'est choisir

Sémiologie graphique : un cadre théorique (Bertin 1967)

Jacques Bertin, géographe, a posé en 1967 les fondations de la sémiologie graphique. Six **variables visuelles** sont à disposition pour encoder de l'information :

Variable	Type de donnée encodable
Taille	Quantitative
Valeur (clair → foncé)	Ordinale ou quantitative
Grain / texture	Ordinale
Couleur (teinte)	Catégorielle
Orientation	Catégorielle
Forme	Catégorielle

Pour une **choroplèthe** (carte par polygones colorés) → variable « valeur » sur palette séquentielle. Pour des **proportions** comparées → variable «

Choroplèthes : choisir un découpage

Pour transformer une variable continue (densité, taux d'électrification) en classes colorées, plusieurs algorithmes :

Méthode	Logique	Quand l'utiliser
Intervalles égaux	Découpe l'amplitude en n parts égales	Données uniformément distribuées
Quantiles	Chaque classe a le même nombre d'unités	Garantit la lisibilité de la légende
Jenks (Fisher-Jenks)	Maximise la variance inter-classe	Distributions très inégales
Manuel	Seuils choisis par expert	Comparaisons à des seuils réglementaires (taux de pauvreté, etc.)

Le choix de la méthode change la carte. Une même donnée avec deux découpages peut raconter deux histoires opposées.

Palettes de couleurs : ColorBrewer et viridis

Trois familles de palettes selon le type de donnée :

Type	Exemple	Palettes
Séquentielle	Densité de population	Blues, YlOrRd, viridis
Divergente	Écart à une moyenne, positif / négatif	RdBu, BrBG, PiYG
Catégorielle	Régions, types de sol	Set3, Paired, Dark2

Critères de choix : daltonien-friendly (vérifier avec `colorblindr::cvd_grid`), imprimable en niveaux de gris, contraste minimal de 3:1 entre classes adjacentes.

`viridis` (Liu & Heer 2018) est le défaut moderne — perceptuellement uniforme, daltonien-friendly, lisible en N&B.

Trois moteurs de carte en R

Moteur	Quand l'utiliser
<code>plot()</code> (base R)	Vérification rapide pendant le développement
<code>ggplot2 + geom_sf</code>	Cartes scientifiques personnalisables, intégration aux autres <code>ggplot</code>
<code>tmap v4</code>	Cartographie thématique publiable, mode statique + interactif, gestion native des classifications

La démo de cet après-midi balaie les trois — la même donnée, trois moteurs, trois esthétiques. À toi de choisir lequel devient ton « moteur principal ».

La carte n'est pas le territoire (Korzybski 1933)

« *Une carte n'est pas le territoire qu'elle représente, mais si elle est correcte, elle a une structure semblable à ce territoire — ce qui en fait l'utilité. »*

— Alfred Korzybski, *Science and Sanity*, 1933.

Implications pratiques pour un démographe :

Partie 7 — Cadrage RGPH 4 Cameroun

Le calendrier 2026-2027

Phase	Période	Activité
Tests pilotes	2025 (passés)	Bamenda 1, Fongo Tongo, Buea, Mora
Cartographie censitaire	2026 H1	Délimitation des zones de dénombrement
Dénombrement principal	2026 H2	Collecte sur le terrain
Traitement et publication	2027	Tableaux + microfichiers

Cet atelier (juillet–août 2026) tombe **pendant la phase de cartographie**. Plusieurs participants seront directement impliqués dans le traitement ultérieur des données.

La méthodologie hybride du RGPH 4

Le RGPH 4 est le premier recensement camerounais à combiner plusieurs sources spatiales :

Source	Apport	Producteur
Dénombrement classique	Effectifs officiels par zone de dénombrement	BUCREP
Imagerie satellite récente	Identification des structures bâties	UNFPA + WorldPop
Modèles top-down 100 m	Raster de population pré-recensement	WorldPop
Modèle bottom-up bayésien	Estimation post-stratification	GDSG / IFORD (méthodo Darin & Leasure 2023)
Données auxiliaires	Routes, sol, NDVI, élévation	FAO + multiples

C'est cette hybridation qui justifie la **profondeur géospatiale** demandée pendant les 10 jours.

Top-down et bottom-up : deux méthodologies complémentaires

Top-down (WorldPop classique (Stevens et al. 2015))

- Part d'un total national connu
- **Désagrège** sur une grille de 100 m × 100 m
- Utilise des covariables (bâti, route, NDVI...) comme « poids »
- Forces : couverture globale, comparabilité
- Limites : suppose une vérité au niveau national

Bottom-up (Darin & Leasure 2023 (Darin and Leasure 2023))

- Part de **micro-recensements** sur clusters géolocalisés
- **Agrège** vers un niveau supérieur via modèle bayésien
- Quantifie l'incertitude par pixel
- Forces : pas besoin de total national fiable
- Limites : exige une enquête échantillonnée propre

Les deux ne s'opposent pas — elles se valident mutuellement. Le RGPH 4 utilise les deux en parallèle. J8 et J9 de cet atelier sont dédiés à chacune.

Sites pilotes RGPH 4 : pourquoi ces quatre-là

Site	Région	Caractéristique pédagogique
Bamenda 1	Nord-Ouest	Capitale régionale, contexte sécuritaire fragile (zone anglophone)
Fongo-Tongo	Ouest	Petite commune rurale du Haut-Plateau, densité forte
Buea	Sud-Ouest	Mont Cameroun, gradient altitudinal, urbain-rural mixte
Mora	Extrême-Nord	Sahel, déplacés internes Boko Haram, accessibilité limitée

Partie 8 — Synthèse et passage à la pratique

Cinq idées-clés à retenir de J1

1. **Un objet spatial est un `data.frame` augmenté d'une colonne `geometry`.** Pas plus, pas moins. Tout `dplyr` y fonctionne.
2. **Le format Simple Features est un standard ouvert international** — interopérable QGIS, PostGIS, ArcGIS. `sf` (R) l'implémente fidèlement.
3. **Aucune projection n'est neutre.** Choisir un CRS, c'est choisir ce qu'on préserve (angles, aires, distances) et ce qu'on sacrifie.
4. **Web Mercator est interdit pour la statistique.** Pour le Cameroun : UTM 32 N / 33 N selon la longitude, ou Lambert Cameroun (EPSG:3119) pour les calculs nationaux.
5. **Le RGPH 4 est une opportunité méthodologique unique** — première combinaison BUCREP + WorldPop + bottom-up à cette échelle en Afrique.

Articulation pratique : ce qu'on a vu vs ce qu'on va faire

Vu en théorie (slides)

- Écosystème R / R-spatial
- Tidy data, verbes dplyr
- Simple Features OGC
- Trois familles de CRS
- Sémiologie graphique
- Cadre RGPH 4

À pratiquer (démonstration + exercices)

- Créer un projet RStudio + [here](#)
- Manipuler un microfichier simulé EDS-MICS
- Charger GADM v4.1 Cameroun
- Reprojecter UTM 32 N
- Calculer une superficie en km²
- Produire une choroplèthe densité

Devoir individuel (Q6 — 30 min, à faire le soir)

Énoncé complet dans

[pedagogie/J01_intro_R_pensee_spatiale/exercice.qmd](#).

Résumé :

1. Créer un projet RStudio personnel.
2. Charger les ADM3 du Cameroun via `fetch_gadm_cameroon(3)`.
3. **Filtrer la région d'origine** (la tienne — Centre, Extrême-Nord, Sud-Ouest, etc.).
4. Reprojecter en UTM 32 N.
5. Produire une carte des arrondissements avec `tmap`.
6. Exporter en `.png` 300 dpi.

Corrigé pédagogique dans [corrige.qmd](#), à n'ouvrir qu'**après** ta tentative.

Demain (J2) — ce qu'on attaque

`sf` en profondeur :

- Lecture / écriture multi-format (Shapefile, GeoJSON, GeoPackage, KML).
- Opérations vectorielles : `st_buffer`, `st_union`, `st_intersection`, `st_centroid`, `st_voronoi`.
- Dissolution des polygones ADM3 → ADM1 (recoller les départements pour obtenir une région).
- Validation et réparation des géométries (`st_make_valid`).
- Premiers fichiers BUCREP officiels si disponibles d'ici là.

Sources de données et licences

Donnée	Source	Licence
GADM v4.1 ADM0-3 Cameroun	https://gadm.org/download_country.html	Libre académique
Estimations population régionale 2019	BUCREP (ordres de grandeur pédagogiques, à actualiser RGPH 4)	À actualiser
Microfichier EDS- MICS Cameroun 2018	https://dhsprogram.com/	DHS Program (inscription + projet)
WorldPop 2020 100 m	https://hub.worldpop.org/	CC-BY 4.0

Code distribué sous **CC-BY 4.0** au nom du GDSG / IFORD.

Références méthodologiques

Pebesma (2018) — fondation théorique de [sf](#).

Wickham (2014) — la théorie tidy data.

Stevens et al. (2015) — méthodologie WorldPop top-down.

Darin and Leasure (2023) — méthodologie WorldPop bottom-up.

Tatem (2017) — vue d'ensemble de l'écosystème WorldPop.

Hijmans (2024) — la documentation [terra](#) (utilisée à partir de J4).

Questions ?

À ce stade, **arrêtons-nous**.

Avant d'attaquer le matériel pratique de demain, vérifions que tout le monde est sur la même longueur d'onde sur :

1. Tidy data + cinq verbes dplyr
2. Simple Features = data.frame + geometry
3. La différence WGS 84 / UTM / Web Mercator
4. Le double pipe top-down × bottom-up du RGPH 4

ramondzita@gmail.com · Geospatial Data Science Group · IFORD

Darin, Edith, and Douglas R. Leasure. 2023. *The bottom-up population modelling pipeline*. WorldPop, University of Southampton / University of Oxford.

Hijmans, Robert J. 2024. *terra: Spatial Data Analysis*.

Pebesma, Edzer. 2018. "Simple Features for R: Standardized Support for Spatial Vector Data." *The R Journal* 10 (1): 439–46.

Stevens, Forrest R., Andrea E. Gaughan, Catherine Linard, and Andrew J. Tatem. 2015.

"Disaggregating Census Data for Population Mapping Using Random Forests with Remotely-Sensed and Ancillary Data." *PLoS ONE* 10 (2): e0107042.

<https://doi.org/10.1371/journal.pone.0107042>.

Tatem, Andrew J. 2017. "WorldPop, open data for spatial demography." *Scientific Data* 4: 170004.

<https://doi.org/10.1038/sdata.2017.4>.