

J2 — Données vectorielles *sf* et CRS

Atelier IFORD × GDSG · Yaoundé · 28 juillet 2026

Ramesesse Dzita · Geospatial Data Science Group

2026-07-28

Partie 0 — Reprise de J1 et plan J2

Ce qu'on a vu hier

R + dplyr

- Cinq verbes : `filter`, `select`, `mutate`, `group_by` + `summarise`, `arrange`
- Pipe `|>` lisible à voix haute
- Tidy data (Wickham 2014)

Premier contact sf

- Un `sf` = `data.frame` + colonne `geometry`
- Trois CRS clés : 4326 (WGS 84), 32632 (UTM 32 N), 3857 (Web Mercator)
- `st_transform()` reprojette, `st_set_crs()` étiquette
- `st_area()`, `st_distance()`, `st_bbox()`

Synthèse du devoir Q6 (la veille)

Avant d'attaquer, on revient 10 minutes sur **votre carte de la région d'origine**.

Trois questions à débattre en salle :

1. Quel CRS as-tu choisi ? Pourquoi ?
2. Combien d'arrondissements ta région contient-elle ? Le chiffre correspond-il à ce que tu connais du terrain ?
3. Sur quoi as-tu buté (libellé exact, palette, taille du texte) ?

J2 — Plan détaillé (8 h)

Bloc	Durée	Format
Wrap-up J1 + intro J2	30 min	Slides
Théorie 1 — Lecture/ écriture multi-format	45 min	Slides
Démo 1 — shp, gpkg, geojson, kml	1 h	demo + Q1
Théorie 2 — CRS appliqué	45 min	Slides
Démo 2 — Reprojection, superficies	1 h	demo + Q2
Théorie 3 — Opérations vectorielles	1 h	Slides
Démo 3 — buffer, intersection, dissolve, voronoi	1 h 30	demo + Q3–Q5

Partie 1 — Lecture et écriture multi-format

Le paysage des formats vectoriels

Quatre formats dominants en démographie spatiale :

Format	Extension	Atouts	Limites
Shapefile	.shp + .shx + .dbf + .prj + .cpg	Standard de fait depuis 1998, lu partout	4 fichiers à transporter ensemble, noms de colonnes ≤ 10 caractères, pas de NULL natif
GeoJSON	.json ou .geojson	Texte lisible, web- friendly, un seul fichier	Gros volumes lourds (texte)
GeoPackage	.gpkg	Format SQLite moderne, OGC standard, plusieurs couches dans un fichier	Adoption plus récente, certains anciens outils ne le lisent pas

Format	Extension	Atouts	Limites
KML / KMZ	.kml ou .kmz	Google Earth, partage avec non-techniciens	Limité aux attributs simples

Convention 2026 : GeoPackage par défaut pour la production, GeoJSON pour le partage web, Shapefile pour la rétro-compatibilité.

sf lit et écrit tous les formats GDAL

Une seule fonction pour lire : `sf::read_sf()` (alias de `st_read()`). Une seule pour écrire : `sf::write_sf()` (alias de `st_write()`).

`sf` repose sur GDAL (cf. J1), qui supporte **plus de 100 formats** vectoriels. La fonction détecte le format à partir de l'extension du fichier.

Un seul appel — `read_sf("ma_couche.shp")` ou `read_sf("ma_couche.gpkg")` — quel que soit le format. C'est la beauté de la couche d'abstraction GDAL.

Les Shapefiles : convention non écrite

Quand quelqu'un te transmet « le Shapefile », il s'agit en réalité d'**au moins 4 fichiers** qui doivent voyager ensemble dans le même dossier :

Fichier	Rôle
.shp	Géométries (binaire)
.shx	Index des géométries (binaire)
.dbf	Attributs (format dBase)
.prj	CRS (texte WKT)
.cpg	Encodage des attributs (optionnel mais salvateur pour les accents)

Erreur classique : un participant t'envoie seulement le **.shp**. La lecture par **sf** plante. **Toujours zipper les 5 fichiers ensemble** quand on partage un Shapefile.

Lire une couche : trois patterns courants

Pattern 1 — fichier simple :

```
adm1 <- read_sf("gadm41_CM1.1.json")
```

Pattern 2 — GeoPackage multi-couches :

```
st_layers("CM1_all.gpkg")           # lister les couches disponibles  
adm1 <- read_sf("CM1_all.gpkg", layer = "ADM1")  
adm3 <- read_sf("CM1_all.gpkg", layer = "ADM3")
```

Pattern 3 — filtrer dès la lecture (très efficace sur gros fichiers) :

```
litoral <- read_sf("gadm41_CM1.1.json", query = "SELECT * FROM gadm41_CM1_1 WHERE NAME_1 = 'Littoral'")
```

Le `query` = est un SQL géré par GDAL : on ne charge en mémoire que ce qu'on veut.

Écrire : convention de production propre

```
write_sf(adm1_pop, "outputs/CMR_adm1_pop.gpkg",  
         layer = "adm1_densite",  
         delete_dsn = TRUE) # remplace si existe
```

Bonnes pratiques :

- Toujours préciser `delete_dsn = TRUE` ou `delete_layer = TRUE` si l'on veut écraser une couche existante (sinon `sf` jette une erreur).
- Privilégier `.gpkg` plutôt que `.shp` pour la production : noms de colonnes longs, encodage UTF-8, valeurs NULL préservées.
- Inclure le CRS dans le nom du fichier si reproductibilité critique : `CMR_adm1_pop_UTM32N.gpkg`.

Partie 2 — CRS appliqué : choisir et reprojeter

Le triple choix : pourquoi, quoi, comment

Trois questions à se poser avant toute opération spatiale :

1. **Pourquoi un CRS projeté ?** Pour mesurer (distances, aires) ou pour cartographier de façon non déformée.
2. **Quel CRS choisir ?** Selon l'emprise géographique et la propriété qu'on veut préserver (cf. famille équivalente / conforme / équidistante de J1).
3. **Comment basculer ?** Une seule fonction : `st_transform()`.

Pour le Cameroun : trois CRS à connaître

EPSG	Nom	Quand l'utiliser
4326	WGS 84 géographique	Stockage GPS, échange entre systèmes, GeoJSON / KML / GPS terrain
32632	UTM zone 32 N	Calcul de distances et superficies à l' ouest du Cameroun (longitudes < 12°)
32633	UTM zone 33 N	Idem pour l' est du pays (longitudes ≥ 12°)
3119	Lambert Cameroun	Cartographie nationale uniforme avec faible déformation

Les zones UTM : pourquoi deux fuseaux ?

UTM (Universal Transverse Mercator) découpe la Terre en **60 fuseaux** de 6° de longitude chacun. La déformation est faible **à l'intérieur** d'un fuseau ($\leq 0.04 \%$) mais explose en s'en éloignant.

Le Cameroun est à cheval sur les fuseaux 32 (longitudes 6°–12° E) et 33 (longitudes 12°–18° E) :

- Ouest (Bafoussam, Buea, Yaoundé, Douala) → fuseau 32 N → EPSG:32632
- Est (Bertoua, Ngaoundéré, Garoua) → fuseau 33 N → EPSG:32633

Pour les calculs nationaux qui mélangent les deux zones, **Lambert Cameroun (3119)** évite la coupure UTM.

La règle d'or de la reprojection

Une seule règle : **reprojeter le plus tard possible**. Idéalement, on garde les données en WGS 84 jusqu'au moment où on a besoin d'un calcul de distance ou d'aire, et **alors seulement** on reprojette pour ce calcul.

Pourquoi ? Trois raisons :

1. Toute reprojection introduit une **erreur de calcul** (transformation numérique).
2. Les données d'origine sont presque toujours fournies en WGS 84 — c'est le format d'échange standard.
3. On peut faire toutes les opérations vectorielles (filtrage attributaire, jointures, sélection) sans avoir besoin de reprojeter.

L'erreur du débutant : `set_crs` confondu avec `transform`

Re-rappel rapide vu en J1 — c'est tellement fréquent qu'on le re-pose.

`st_set_crs(x, 4326)`

= « ÉTIQUETTE en WGS 84 »

— ne touche **pas** aux coordonnées.

Utile uniquement si le CRS est absent (Shapefile sans `.prj`).

`st_transform(x, 4326)`

= « REPROJETTE vers WGS 84 »

— **recalcule** chaque coordonnée.

C'est ce qu'on veut 99 % du temps.

Partie 3 — Opérations vectorielles

Une opération géométrique = une question spatiale

Chaque opération `sf` répond à une question concrète :

Fonction	Question
<code>st_buffer(x, d)</code>	Quelle zone autour de <code>x</code> à une distance $\leq d$?
<code>st_intersection(x, y)</code>	Quelle est la portion commune à <code>x</code> et <code>y</code> ?
<code>st_difference(x, y)</code>	Quelle est <code>x</code> privée de <code>y</code> ?
<code>st_union(x)</code>	Quelle est la fusion de tous les <code>x</code> en un seul polygone ?
<code>st_centroid(x)</code>	Quel est le « centre » géométrique de <code>x</code> ?
<code>st_voronoi(x)</code>	Quelle est la zone d'influence de chaque point de <code>x</code> ?
<code>st_is_valid(x)</code>	Les géométries sont-elles bien formées ?

st_buffer — zone tampon

`st_buffer(x, dist = 5000)` retourne tous les points à **moins de 5 000 mètres** de `x`. Pour que cette distance soit en mètres, **il faut que `x` soit en CRS projeté** (UTM ou Lambert), pas en WGS 84.

Cas d'usage démographique :

- Zone d'attraction d'un hôpital (rayon de 5 km).
- Frontière administrative étendue (buffer de 1 km pour gérer une couture).
- Aire de service d'une école (distance scolaire).

st_intersection — la portion commune

`st_intersection(zones, parcelles)` retourne la **portion de chaque parcelle qui tombe dans une zone**. Les attributs des deux couches sont préservés.

Cas d'usage démographique :

- Quels arrondissements tombent dans le buffer d'un site pilote RGPH 4 ?
- Quelle portion d'un raster WorldPop tombe dans une zone protégée ?

! Performance

`st_intersection` est lent sur des gros volumes. Si on doit croiser 1000 polygones avec 1 million de points, préférer `st_join(..., join = st_intersects)` qui est optimisé pour ce cas.

st_union — fusionner

Deux usages distincts :

Fusion totale : tous les polygones deviennent un seul.

```
cmr_silhouette <- st_union(adm1) # 10 régions → 1 polygone "Cameroun"
```

Dissolve par groupe : agréger ADM3 en ADM2 par exemple.

```
adm1_from_adm3 <- adm3 |>  
  group_by(NAME_1) |>  
  summarise(geometry = st_union(geometry))
```

C'est l'opération **dissolve** classique en SIG — agréger une couche fine en une couche grossière par identifiant.

st_centroid — réduire un polygone à son centre

Le centroïde géométrique est utile pour :

- Placer un texte au centre d'un polygone.
- Construire un diagramme de Voronoï à partir des centres administratifs.
- Calculer une « distance entre régions » (centroïde-à-centroïde).

Centroïde ≠ chef-lieu

Le centroïde géométrique d'une région **n'est pas** son chef-lieu. Pour Yaoundé (Centre) ou Douala (Littoral), il vaut mieux utiliser les vraies coordonnées GPS du chef-lieu plutôt que le centroïde.

st_voronoi — zone d'influence

Le diagramme de Voronoï d'un ensemble de points partitionne le plan en cellules : chaque cellule contient tous les lieux **plus proches du point *i*** que de n'importe quel autre point.

Cas d'usage démographique :

- Zone d'influence d'un chef-lieu régional.
- Aire d'attraction d'un hôpital, d'une école.
- Cellules de dénombrement RGPH (en complément du découpage admin).

C'est l'opération qu'on fera en démo 3 sur les **10 chefs-lieux régionaux** du Cameroun.

Géométries malformées : pourquoi et comment réparer

Une géométrie « malformée » viole un invariant OGC : auto-intersection d'un polygone, anneau ouvert, multiline avec doublons. Les causes habituelles :

- Numérisation manuelle (digitization), erreurs humaines.
- Simplifications agressives qui pincent des polygones.
- Reprojections sur les zones de coupure (à 180°, aux pôles).

Diagnostic et réparation :

```
st_is_valid(adm1)           # logique TRUE/FALSE par feature
adm1_clean <- st_make_valid(adm1)
```

`st_make_valid` utilise l'algorithme GEOS pour fermer les anneaux, supprimer les auto-intersections, fusionner les doublons. **Toujours faire un `st_make_valid()` après une reprojection.**

Partie 4 — Cadrage spécifique

RGPH 4

Pourquoi les opérations vectorielles comptent pour le RGPH 4

Le BUCREP doit produire d'ici 2027 :

1. Les **zones de dénombrement** (ZD) — petites unités opérationnelles couvrant l'ensemble du territoire sans chevauchement.
2. Les **limites administratives** mises à jour (ADM3 a évolué depuis le dernier RGPH).
3. Les **micro-zones** pour les estimations bottom-up.

Tous ces produits exigent des opérations **sf** propres : dissolve, intersection, validation. C'est ce qu'on travaille aujourd'hui.

Anatomie d'un Shapefile BUCREP type

Quand tu récupères un Shapefile BUCREP officiel, tu trouveras typiquement :

Colonne	Type	Note
ID_ZD	character	Identifiant unique de la zone de dénombrement
ID_ARR	character	Identifiant de l'arrondissement
NOM_ARR	character	Nom officiel
NOM_DEP	character	Département
NOM_REG	character	Région
POP_2005	numeric	Population au dernier RGPH (RGPH 3, 2005)
geometry	sfc_POLYGON	Forme

Les attributs sont en français, encodage UTF-8 (espérons-le, sinon `read_sf(..., options = "ENCODING=UTF-8")`).

Partie 5 — Synthèse

Cinq idées-clés à retenir de J2

1. **Un seul appel suffit pour lire ou écrire** un fichier spatial — `read_sf()` / `write_sf()`. GDAL gère le format sous le capot.
2. **GeoPackage est le format moderne par défaut** ; Shapefile reste pour rétro-compatibilité.
3. **Reprojeter le plus tard possible**. Stocker en WGS 84, reprojeter pour le calcul ou la carte.
4. **Lambert Cameroun (EPSG:3119)** pour les calculs nationaux ; UTM 32 N / 33 N pour les calculs régionaux.
5. **Dissolve = group_by + st_union** ; Voronoï construit des zones d'influence ; `st_make_valid` répare les géométries après reprojektion.

Articulation avec la démo et les exercices

Vu en théorie (slides)

- Formats vectoriels et leurs usages
- Trois CRS clés du Cameroun
- Sept opérations vectorielles
- Validation des géométries
- Cadrage RGPH 4

À pratiquer (démo + exercices)

- Lire un .shp, un .gpkg, un .geojson
- Reprojecter UTM 32 N ↔ Lambert 3119
- Buffer 50 km autour des chefs-lieux
- Dissolve ADM3 → ADM1
- Voronoï des 10 chefs-lieux

Devoir individuel (Q6 — 30 min)

Énoncé complet dans [pedagogie/J02_sf_CRS_vecteurs/exercice.qmd](#).

Résumé : à partir des ADM2 (départements) du Cameroun, construire un GeoPackage avec deux couches — la couche départementale (ADM2) avec la superficie, et la couche régionale (ADM1) reconstituée par dissolve.

Demain (J3) — Données raster avec terra

terra en profondeur :

- Concepts raster : résolution, étendue, CRS, bandes.
- Sept opérations fondamentales (`crop`, `mask`, `resample`, `aggregate`, `project`, `extract`, `global`).
- Algèbre raster cellule à cellule.
- Combinaison raster + vecteur (extraction zonale).
- Cas concret : MNT SRTM Cameroun, élévation moyenne par région.

Sources et licences

Donnée	Source	Licence
GADM v4.1 ADM0–3 Cameroun	https://gadm.org/download_country.html	Libre académique
Polygones BUCREP (si dispo)	BUCREP, Yaoundé	Usage atelier autorisé

Code distribué sous **CC-BY 4.0** au nom du GDSG / IFORD.

Références méthodologiques

Pebesma ([2018](#)) ; Hijmans ([2024](#)) ; Bureau Central des Recensements et des Études de Population (BUCREP) ([2026](#)).

Questions ?

À ce stade, **arrêtons-nous**.

Avant d'attaquer le matériel pratique, vérifions que tout le monde est sur :

1. La distinction `set_crs` $\neq$ `transform`
2. L'analogie `dissolve` = `group_by` + `st_union`
3. La règle « reprojeter le plus tard possible »

ramondzita@gmail.com · Geospatial Data Science Group · IFORD

Bureau Central des Recensements et des Études de Population (BUCREP). 2026. *Quatrième Recensement Général de la Population et de l'Habitat du Cameroun (RGPH 4)*. République du Cameroun.

Hijmans, Robert J. 2024. *terra: Spatial Data Analysis*.

Pebesma, Edzer. 2018. "Simple Features for R: Standardized Support for Spatial Vector Data." *The R Journal* 10 (1): 439–46.