

J10 — Flux de travail reproductibles et renforcement des capacités

Atelier IFORD × GDSG · Yaoundé · 6 août 2026

Ramesesse Dzita · Geospatial Data Science Group

2026-08-06

Partie 0 — Bienvenue au dernier jour

Où en sommes-nous ?

Vous arrivez **au bout** d'un atelier de 10 jours. Récap :

Jour	Thème
J1	Intro R + pensée spatiale
J2	Données vectorielles sf
J3	Données raster avec terra
J4	Gestion des données pour l'analyse spatiale
J5	Visualisation et cartographie
J6	Statistiques spatiales (Moran, LISA, KDE)
J7	Cartographie population haute résolution + bottom-up
J8	Télédétection et observation de la Terre
J9	Sciences spatiales et sociales : projets inspirants
J10	Reproductibilité + restitutions + clôture

Pourquoi un dernier jour sur la reproductibilité ?

Trois raisons :

1. **Le code produit n'a de valeur que si on peut l'exécuter à nouveau** — chez vous, six mois plus tard, sur un autre ordinateur.
2. **Le RGPH 4 exige des chaînes de traitement auditable** — chaque chiffre publié doit être traçable jusqu'à sa source.
3. **La science ouverte impose** que les analyses soient partageables, vérifiables, réutilisables (principes FAIR).

Une analyse non reproductible est, en pratique, perdue dès qu'on ferme RStudio.

Plan détaillé J10

Bloc	Durée
Wrap-up J1–J9 + intro J10	30 min
Théorie 1 — Pourquoi la reproductibilité ?	30 min
Démo 1 — Construire un rapport Quarto	1 h
Théorie 2 — Versioning avec Git	30 min
Démo 2 — Init Git + commit + push	45 min
Théorie 3 — Automatisation	30 min
Démo 3 — Fonction + boucle batch	30 min
Présentations courtes	1 h
Session clôture : FAIR + métadonnées + feuille route INS	30 min
Q&A + remise certificats	30 min

Partie 1 — Pourquoi la reproductibilité ?

Le test des six mois

Imaginez que **six mois après l'atelier**, votre directeur vous demande : « peux-tu refaire l'analyse de septembre, avec les données d'octobre ? ».

Si votre travail est reproductible :

- Vous ouvrez votre repo, mettez à jour le fichier de données, relancez le pipeline, livrez en 30 minutes.

S'il ne l'est pas :

- Vous passez deux jours à essayer de retrouver « comment vous aviez fait », sans y arriver complètement.

Les cinq piliers d'un workflow reproductible

Pilier	Outil R / standard
1. Projet structuré	Projet RStudio avec <code>here::here()</code> pour les chemins
2. Code documenté	Quarto / R Markdown avec narration scientifique
3. Versioning du code	Git + plateforme (GitHub, GitLab)
4. Gestion des dépendances	<code>renv</code> pour figer les versions de packages
5. Métadonnées des données	ISO 19115 ou Dublin Core, fichiers <code>README</code>

Trois niveaux de reproductibilité

Niveau	Définition	Effort
Reproductibilité méthodologique	« Quelqu'un d'autre, avec les mêmes données, obtient les mêmes résultats »	Moyen
Reproductibilité computationnelle	« N'importe qui, sur n'importe quelle machine, retrouve les chiffres exacts »	Élevé — exige <code>renv</code> ou Docker
Reproductibilité scientifique	« Avec d'autres données comparables, on retrouve les mêmes conclusions »	Le plus élevé — exige plusieurs études

Pour l'atelier : on vise le niveau **méthodologique** (un projet RStudio versionné Git, un Quarto exécutable).

Partie 2 — Quarto pour les rapports reproductibles

Anatomie d'un rapport Quarto

Un fichier `.qmd` est du texte Markdown + des blocs de code R (ou Python, Julia) + une YAML d'en-tête.

```
---  
title: "Mon rapport"  
author: "Mon nom"  
format: pdf  
---  
  
# Introduction  
  
Le Cameroun compte 10 régions :  
  
{r}  
library(sf)  
adm1 <- read_sf(...)  
nrow(adm1)
```

À la commande `quarto render rapport.qmd`, Quarto exécute le code R, capture les sorties, et produit un PDF ou HTML.

L'avantage : code + narration + résultats dans un seul fichier

Sans Quarto

- Le code est dans `analyse.R`.
- Les graphiques sont sauvegardés en PNG.
- Le rapport est rédigé dans Word.
- À chaque modification de données, refaire tout manuellement.

Avec Quarto

- Code + texte + graphiques **dans un seul .qmd**.
- À chaque modification de données : `quarto render` re-génère tout en automatique.
- Sortie PDF, HTML, Word, et même slides revealjs depuis la **même source**.

Le standard scientifique en 2026

Quarto est **adopté massivement** depuis 2023 :

- *Nature*, *Science* recommandent la soumission de matériel supplémentaire en R Markdown / Quarto.
- *JAMA Network* exige des données + code reproductibles.
- WorldPop, le DHS Program, l'INED publient leur méthode en Quarto.
- Le BUCREP devrait s'aligner sur cette pratique pour le RGPH 4.

Partie 3 — Versioning avec Git

Le problème que Git résout

Sans Git, votre arborescence ressemble vite à :

```
analyse_v1.R  
analyse_v2.R  
analyse_v3_FINAL.R  
analyse_v3_FINAL_corrigé.R  
analyse_v3_FINAL_corrigé_VRAIMENT_FINAL.R
```

Avec Git, vous avez **un seul fichier** `analyse.R`, et l'historique de **toutes ses versions** est dans un sous-dossier `.git`. Vous pouvez revenir à n'importe quelle version précédente en une commande.

Trois opérations Git de base

Commande	Action
<code>git status</code>	Voir ce qui a changé depuis le dernier commit
<code>git add fichier.R</code>	Préparer un fichier pour le commit
<code>git commit -m "Message"</code>	Enregistrer un instantané
<code>git push</code>	Envoyer les commits vers GitHub
<code>git pull</code>	Récupérer les commits depuis GitHub

Un commit par modification cohérente. Pas par jour, pas par fichier. Une logique = un commit.

Bonne pratique : messages de commit

✗ Mauvais	✓ Bon
« MAJ »	« Ajouter Q4 corrigé — distance Bamenda-Buea »
« update »	« Corriger CRS dans la fonction <code>dissolve_adm()</code> »
« Pour Pierre »	« Refonte du chapitre 3 selon retours de M. Kuepié »

Les messages sont lus dans 6 mois — ils doivent être interprétables hors contexte.

GitHub comme infrastructure publique

GitHub n'est pas qu'un stockage de code. C'est une **infrastructure de collaboration** :

- **Issues** : suivre les bugs et idées (chaque problème a son fil de discussion).
- **Pull requests** : proposer des modifications, les faire relire.
- **Actions** : automatiser des tâches (cf. notre déploiement du runtime WebR).
- **Pages** : héberger un site web statique gratuit (notre runtime en ligne).

Partie 4 — Automatisation

La règle des trois

Toute tâche **répétée trois fois** mérite d'être automatisée.

Exemples typiques en analyse spatiale :

- Calculer le même indicateur pour 10 régions → fonction + boucle.
- Produire une carte mensuelle → fonction qui prend le mois en paramètre.
- Vérifier 365 fichiers de données → fonction qui scanne un dossier.

Trois outils d'automatisation en R

Outil	Quand l'utiliser
<code>for</code> boucle	Pour 2–3 itérations simples
<code>purrr::map_*</code>	Boucle fonctionnelle, sortie typée, code lisible
Script + Rscript	Automatisation système (cron)

Exemple : calculer la densité pour chaque région

```
library(purrr)
library(sf)

# Une fonction qui prend un nom de région et retourne la densité
densite_region <- function(nom) {
  region <- adm1 |> filter(NAME_1 == nom)
  pop <- pop_par_region[pop_par_region$NAME_1 == nom, "pop_2020"]
  superficie <- as.numeric(st_area(region)) / 1e6
  tibble(region = nom, densite = pop / superficie)
}

# Appliquer à toutes les régions
resultats <- map_dfr(adm1$NAME_1, densite_region)
```

`map_dfr` applique la fonction à chaque élément et combine les résultats en un seul tibble. C'est l'équivalent fonctionnel d'une boucle.

Partie 5 — Présentations courtes

Format

Chaque participant (ou binôme) présente **5 à 8 minutes** sur :

- Une carte, une analyse, un script qu'il a produit pendant les 9 jours.
- Ce qu'il a appris en le faisant.
- Comment il compte réutiliser cet outil dans son institution.

L'objectif n'est pas la perfection technique — c'est de **partager une compétence acquise**.

Tous les profils sont valorisés

Profil	Type de présentation typique
Statisticien INS	Carte d'un indicateur ECAM par région avec décoration soignée
Démographe IFORD	Comparaison top-down/bottom-up sur un département pilote
Technicien ministère sectoriel	Application au secteur d'attache (santé, éducation, agriculture)
Cadre ONG	Cartographie d'un programme géré par l'institution

Partie 6 — Principes FAIR et clôture

Les principes FAIR (2016)

Quatre principes pour la **science ouverte** :

Lettre	Principe	Implication pratique
F	Findable (Trouvable)	Identifiant unique (DOI), métadonnées complètes, indexé dans un catalogue
A	Accessible (Accessible)	Protocoles standards (HTTPS), authentification claire, archivage long terme
I	Interoperable (Interopérable)	Formats ouverts (GeoPackage, NetCDF), vocabulaires standardisés (CF Conventions)
R	Reusable (Réutilisable)	Licence claire (CC-BY recommandé), métadonnées de

Lettre	Principe	Implication pratique
		provenance, documentation

Les principes FAIR sont devenus la **norme de référence** des bailleurs internationaux (UE Horizon, NIH, Wellcome) — toute donnée publique non-FAIR sera de plus en plus rejetée.

Métadonnées géospatiales

Standard	Domaine d'application
ISO 19115	Métadonnées géospatiales générales (le standard de référence pour les SIG nationaux)
Dublin Core étendu	Métadonnées scientifiques génériques
DataCite Schema	DOI pour les jeux de données scientifiques
OGC CSW	Catalogue de services pour la découverte

Pour un INS : les sorties RGPH 4 devraient être documentées en **ISO 19115**, publiées sur un catalogue conforme **OGC CSW** (par exemple via GeoNetwork open source).

Feuille de route pour l'INS / BUCREP

Cinq étapes pour mettre en place une infrastructure de données spatiales (IDS) :

1. **Inventaire** des données spatiales déjà détenues (où, qui, dans quel format).
2. **Standardisation** : convertir tout en formats ouverts (GeoPackage, GeoTIFF cloud-optimisé).
3. **Métadonnées** : documenter chaque jeu en ISO 19115.
4. **Catalogue** : déployer GeoNetwork ou équivalent pour la découverte interne et publique.
5. **Politique de partage** : définir ce qui est public, restreint, interne.

L'IDS du BUCREP, une fois en place, sera **la référence** pour toutes les analyses post-RGPH 4.

Ressources pour continuer

- **Geocomputation with R** (Lovelace, Nowosad, Muenchow) : <https://r.geocompx.org/>
- **Spatial Data Science** (Pebesma, Bivand) : <https://r-spatial.org/book/>
- **R Packages** (Wickham, Bryan) : <https://r-pkgs.org/>
- **Happy Git and GitHub for the useR** (Bryan) : <https://happygitwithr.com/>
- **WorldPop documentation** : <https://www.worldpop.org/>
- **DHS Spatial Analysis Reports** : <https://dhsprogram.com/publications/>
- **Afrimapr** (communauté R-spatial Afrique) : <https://afrimapr.github.io/>

La communauté GDSG après l'atelier

Le **Geospatial Data Science Group** de l'IFORD est ouvert aux anciens de l'atelier :

- Slack / WhatsApp pour les questions techniques.
- Sessions mensuelles de présentation de projets.
- Co-publications scientifiques sur les questions RGPH 4.
- Stages possibles à l'IFORD pour les profils plus jeunes.

Contact : ramondzita@gmail.com (technique) et Pr Kuépié (institutionnel).

Partie 7 — Cérémonie de clôture

Évaluation de l'atelier (questionnaire)

10 questions, 5 minutes max. Anonyme. Lien Forms IFORD distribué.

Trois axes :

1. **Contenu** : les 10 jours étaient-ils équilibrés ? Quel jour était trop dense / trop léger ?
2. **Forme** : qualité des supports (slides, démos, runtimes WebR, exercices) ?
3. **Suite** : besoins de formation continue, formats préférés ?

Vos réponses influenceront les itérations 2027 et au-delà.

Remise des certificats

À l'issue des présentations courtes, **Pr Kuépié** remet les certificats IFORD nominatifs.

Photo officielle de groupe pour la communication institutionnelle.

Pour les institutions qui exigent un **livret pédagogique annexe** : on émet sur demande, listant les compétences validées.

Merci

À vous tous d'avoir suivi ces 10 jours intensifs.

À **Pr Mathias Kuépié, Pr Franklin Bouba Djourdebbé, Edith Darin, Jean Saturnin Alogo Samba, Marcial Teda Soh Fossi** — l'équipe GDSG.

À l'**IFORD** pour l'accueil et l'organisation.

Au **BUCREP** et au **MINEPAT** pour les données et l'appui institutionnel.

ramondzita@gmail.com · Geospatial Data Science Group · IFORD

Bonne continuation. À bientôt sur le terrain.